BÁO CÁO PHÂN TÍCH KẾT QUẢ THỰC NGHIỆM

So sánh sáu kiến trúc CNN cho nhận diện 19 nhóm bệnh, dịch hại và trạng thái trên cây lúa

Kết quả khóa V2 • 18 lượt huấn luyện • 9.829 ảnh kiểm thử

Hạng mục	Giá trị đã kiểm toán
Dữ liệu	65.516 ảnh RGB; train/validation/test = 45.858/9.829/9.829
Thiết kế	6 backbone × 3 seed (42, 123, 2026); cùng protocol PyTorch/torchvision
Tiêu chí chính	Macro-F1 trung bình ± sample SD qua 3 seed
Trạng thái test	Mở theo guard một lần; audit hoàn tất 2026-08-30T07:10:31.355322+00:00

RiceAI Research

Phiên bản 1.0 • 30/08/2026 • Asia/Ho_Chi_Minh

Mục lục nội dung

Tóm tắt điều hành

1. Câu hỏi nghiên cứu và phạm vi bằng chứng

2. Dữ liệu, làm sạch và chiến lược chia tập

3. Sáu kiến trúc và giả thuyết kỹ thuật

4. Protocol huấn luyện, chọn checkpoint và tái lập

5. Quy trình mở test và thước đo đánh giá

6. Kết quả tổng thể và độ ổn định qua seed

7. So sánh bất định bằng paired bootstrap

8. Phân tích sâu từng mô hình

9. Phân tích theo lớp và mẫu lỗi

10. Hiệu quả tài nguyên và hàm ý triển khai mobile

11. Độ giá trị, giới hạn và nguy cơ sai lệch

12. Kết luận và khuyến nghị nghiên cứu

Tài liệu tham khảo

Phụ lục A–D: số liệu chi tiết và provenance

Cách đọc báo cáo: mọi phát biểu có số liệu được truy ngược tới final_comparison.json hoặc test_metrics.json. Những giải thích dựa trên kiến trúc được ghi rõ là giả thuyết hợp lý, không được trình bày như quan hệ nhân quả đã chứng minh.

Tóm tắt điều hành

Kết luận chính: trong protocol đã khóa này, EfficientNet-B0 đạt mean Macro-F1 cao nhất (97,764% ± 0,064%) và đứng đầu cả ba seed. MobileNetV3-Large đứng thứ hai (97,323% ± 0,244%) và vẫn là ứng viên mobile hợp lý, nhưng quyết định triển khai cuối cùng cần benchmark độ trễ, RAM và năng lượng của cả sáu model trên cùng thiết bị/runtime.

Báo cáo phân tích 18 checkpoint (6 mô hình × 3 seed) trên cùng tập test 9.829 ảnh đã khóa. Tiêu chí chính được chốt trước là Macro-F1 vì phân bố lớp rất lệch: stem_borer, brown_planthopper và leaf_roller chiếm 76,539% test. Accuracy vẫn được báo cáo nhưng không được dùng một mình để kết luận chất lượng trên lớp hiếm.

Hạng	Mô hình	Accuracy	Macro-F1	SD F1	Tham số	Checkpoint
1	EfficientNet-B0	99.298%	97.764%	0.064 đ.%	4.032 M	15.67 MiB
2	MobileNetV3-Large	99.132%	97.323%	0.244 đ.%	4.226 M	16.32 MiB
3	ResNet-18	98.898%	96.878%	0.923 đ.%	11.186 M	42.75 MiB
4	DenseNet-121	98.888%	96.658%	0.320 đ.%	6.973 M	27.18 MiB
5	MobileNetV2	98.620%	96.184%	0.922 đ.%	2.248 M	8.81 MiB
6	ShuffleNet V2 1.0×	96.534%	90.971%	1.691 đ.%	1.273 M	5.02 MiB

Bảng 1. Xếp hạng mô tả theo mean Macro-F1. SD là sample SD qua 3 training seed, không phải khoảng tin cậy 95%.

- EfficientNet-B0 có hiệu năng trung bình cao nhất và độ biến thiên seed thấp nhất; hơn MobileNetV3-Large **0,441 điểm % Macro-F1** theo mean.
- MobileNetV3-Large đứng #2 ở seed 123 và 2026, #3 ở seed 42, sát ResNet-18; lợi thế mobile của kiến trúc là cơ sở chọn ứng viên, chưa phải bằng chứng runtime trên OPPO A54.
- ShuffleNet V2 1.0× nhỏ nhất (1,273 triệu tham số) nhưng Macro-F1 thấp nhất và SD lớn nhất; đây là trade-off chất lượng–độ gọn, không tự động đồng nghĩa chậm/nhanh trên thiết bị.
- Các lớp khó nhất xuyên mô hình là downy_mildew, tungro, blast, bacterial_leaf_streak và weeds. Hai lớp đạt 100% ở mọi run có support rất nhỏ (n=12 và n=29), vì vậy không nên quảng bá như kết quả chắc chắn.
- Kết quả chỉ có giá trị nội bộ trên split ảnh phân tầng. Split không nhóm theo cây, ruộng hoặc phiên chụp; chưa có external/geographic/temporal test.

1. Câu hỏi nghiên cứu và phạm vi bằng chứng

Nghiên cứu trả lời câu hỏi: khi giữ cố định dữ liệu, cách tiền xử lý, augmentation, loss, lịch huấn luyện, tiêu chí chọn checkpoint và framework, sáu backbone CNN khác nhau đem lại trade-off nào giữa chất lượng phân loại, độ ổn định và quy mô mô hình cho hệ RiceAI?

1.1 Đối tượng so sánh

- MobileNetV2 và MobileNetV3-Large: họ mạng nhẹ định hướng thiết bị biên/mobile [1], [2].
- ResNet-18: baseline residual cổ điển, có identity shortcut [3].
- EfficientNet-B0: baseline được xây dựng quanh compound scaling depth–width–resolution [4].
- ShuffleNet V2 1.0×: kiến trúc nhẹ dùng channel split/shuffle và nhấn mạnh chi phí truy cập bộ nhớ [5].
- DenseNet-121: kết nối dày đặc để tái sử dụng đặc trưng [6].

1.2 Phạm vi kết luận

Phát biểu đúng: “EfficientNet-B0 đạt mean Macro-F1 cao nhất trong campaign RiceAI V2 trên split test cố định này.” Phát biểu không được phép: “EfficientNet-B0 tốt nhất tuyệt đối cho mọi ruộng lúa, điện thoại và điều kiện chụp.”

2. Dữ liệu, làm sạch và chiến lược chia tập

Tập dữ liệu sau làm sạch gồm 65.516 ảnh RGB thuộc 19 nhãn canonical. Đây không phải 19 bệnh thuần túy: ngoài bệnh còn có sâu hại/đối tượng (beetle, planthoppers, snail, leaf roller, stem borer), cỏ dại và trạng thái normal. Vì vậy báo cáo dùng cụm “19 nhóm bệnh, dịch hại/đối tượng và trạng thái lúa”.

Bước	Số lượng	Diễn giải
File quét ban đầu	67.342	Nguồn trước curation
Exact duplicate bị loại	102	Loại bản sao chính xác
Duplicate chéo nhãn bị loại	1.724 file / 862 nhóm	Loại toàn bộ nhóm xung đột nhãn trước split
Ảnh duy nhất dùng	65.516	Đã full SHA verification trước khóa V2
Train / validation / test	45.858 / 9.829 / 9.829	70% / 15% / 15%, stratified image-level, seed 2026

Bảng 2. Provenance dữ liệu và số lượng dùng trong campaign.

Ba lớp lớn nhất là stem_borer (n=2973), brown_planthopper (n=2786) và leaf_roller (n=1764), tổng cộng 7.523/9.829 ảnh test (76,539%). Năm lớp nhỏ nhất là southern_black_streaked_dwarf (n=12), leaf_smut (n=21), whitebacked_planthopper (n=29), bacterial_panicle_blight (n=50), bacterial_leaf_streak (n=57).

Giới hạn trọng yếu: split được phân tầng ở cấp ảnh, không group theo cây, ruộng hay phiên chụp vì metadata không chứa các group ID đó. Near-duplicate hoặc ảnh tương quan cùng bối cảnh có thể nằm ở nhiều split, làm kết quả nội bộ lạc quan. Roberts et al. khuyến nghị blocking khi dữ liệu có cấu trúc phụ thuộc [15]; Kapoor và Narayanan cũng chỉ ra leakage có thể thổi phồng kết quả khoa học ML [16].

3. Sáu kiến trúc và giả thuyết kỹ thuật

Tất cả backbone dùng official ImageNet-1K weights từ torchvision 0.17.1, classifier được thay bằng 19 đầu ra và dropout 0,4. Vì phiên bản weight enum không đồng nhất (V1/V2), so sánh thực tế là "kiến trúc + official pretrained checkpoint + common recipe", không phải phép cô lập topology thuần túy.

Mô hình	Thành phần kiến trúc nổi bật	Official weight	Tham số 19 lớp	Giả thuyết trước kết quả
MobileNetV2	Depthwise separable; inverted residual; linear bottleneck	IMAGENET1K_V2	2.248.211	Gọn, baseline mobile; có thể thiếu capacity ở lớp hình thái gần
MobileNetV3-Large	Hardware-aware NAS/NetAdapt; SE; hard-swish	IMAGENET1K_V2	4.226.371	Trade-off chất lượng–latency tốt trên mobile, cần đo runtime thật
ResNet-18	Basic residual blocks và identity shortcut	IMAGENET1K_V1	11.186.259	Tối ưu ổn định, baseline mạnh nhưng nhiều tham số
EfficientNet-B0	MBConv + compound scaling cân bằng	IMAGENET1K_V1	4.031.887	Độ chính xác/hiệu quả cao nhờ phân bổ capacity cân bằng
ShuffleNet V2 1.0×	Channel split, channel shuffle, pointwise groups	IMAGENET1K_V1	1.273.079	Rất gọn nhưng có nguy cơ under-capacity cho 19 lớp
DenseNet-121	Dense connectivity, concatenate feature maps	IMAGENET1K_V1	6.973.331	Tái sử dụng đặc trưng tốt; có thể tốn memory traffic

Bảng 3. Lý do chọn sáu backbone. Giả thuyết kiến trúc không thay thế số liệu thực nghiệm.

3.1 Nguyên tắc diễn giải nguyên nhân

Khi EfficientNet-B0 hoặc MobileNetV3-Large đạt kết quả cao, compound scaling, MBConv, squeeze-and-excitation hay hardware-aware search là các cơ chế kiến trúc hợp lý để thảo luận [2], [4]. Tuy nhiên campaign không thực hiện ablation từng thành phần; do đó chỉ được viết "có thể liên quan/phù hợp với", không được viết "do thành phần X gây ra".

Tương tự, ShuffleNet V2 nhấn mạnh rằng FLOPs không đủ dự báo tốc độ vì memory access cost và đặc tính nền tảng cũng quan trọng [5]. DenseNet có tái sử dụng feature [6], nhưng concatenate nhiều feature map có thể làm traffic bộ nhớ đáng kể; điều này cần đo profiler thay vì suy từ số tham số.

4. Protocol huấn luyện, chọn checkpoint và tái lập

4.1 Tiền xử lý và augmentation

- Resize trực tiếp 224×224 bằng bilinear + antialias; chuyển RGB; ToTensor về [0,1].
- Chuẩn hóa ImageNet mean [0,485; 0,456; 0,406] và std [0,229; 0,224; 0,225].
- Train augmentation: horizontal flip p=0,5; RandomAffine rotation ±20,16°, translation 0,1, scale 0,85–1,15; ColorJitter brightness/contrast 0,15.
- Validation/test không augmentation; test shuffle=false và giữ thứ tự manifest.

4.2 Hai giai đoạn transfer learning

1. Stage head: khóa backbone, huấn luyện classifier bằng Adam, LR=1e-3, tối đa 15 epoch.
2. Stage fine-tune: mở toàn mạng trừ BatchNorm, khởi tạo lại optimizer/scheduler, Adam LR=1e-5, tối đa 30 epoch.
3. Weighted cross-entropy theo effective number of samples, β=0,999; chuẩn hóa mean rồi clip [0,25; 5], dựa trên Cui et al. [7].
4. ReduceLROnPlateau theo validation Macro-F1: factor=0,2, patience=2, min LR=1e-7.
5. Early stopping patience=5; bộ đếm reset khi đổi stage nhưng best score/checkpoint là global xuyên hai stage.
6. Checkpoint được chọn duy nhất theo validation Macro-F1; test không tham gia huấn luyện hoặc chọn model.

Thành phần	Cấu hình khóa	Ghi chú kiểm toán
Input / batch / loader	RGB 224×224; batch=32; workers=4	workers lấy từ command trong 18 run_manifest
Classifier	19 đầu ra; dropout=0,4	Tham số báo cáo đã gồm classifier mới
Optimizer	Adam; head LR=1e−3; fine-tune LR=1e−5	Không truyền weight_decay trong mã; mặc định Adam = 0
BatchNorm	Đóng băng running statistics và tham số ở cả hai stage	Giữ cùng chính sách cho sáu backbone
Loss	Weighted cross-entropy; effective number β=0,999	Weight chuẩn hóa mean, clip [0,25; 5]
Scheduler	ReduceLROnPlateau; factor=0,2; patience=2; min LR=1e−7	Theo validation Macro-F1
Dừng / chọn	Early stop patience=5; checkpoint global tốt nhất	Test không tham gia chọn checkpoint
Lặp	Seed 42, 123, 2026	Ba lần huấn luyện độc lập/mô hình

Bảng 4a. Cấu hình thực thi được đối chiếu giữa contract, source code và run manifest.

Revision V2 tăng ngân sách fine-tune từ 15 lên 30 epoch sau pilot chỉ dựa trên validation của MobileNetV2; pilot V1 bị loại khỏi kết quả chính và thay đổi được khóa trước khi mở test. Đây là protocol revision informed by validation, không phải test-driven tuning.

4.3 Kiểm soát tái lập

Campaign đặt seed Python/NumPy/PyTorch/CUDA, bật deterministic algorithms, tắt cuDNN benchmark, bật cuDNN deterministic, đặt CUBLAS_WORKSPACE_CONFIG=:4096:8 và tắt TF32. PyTorch vẫn lưu ý không thể bảo đảm tái lập tuyệt đối qua release, platform hoặc CPU/GPU khác [14].

Thành phần khóa	Định danh / SHA-256
Benchmark contract	e54ea9e3adb1fbb6a82ea29781dc6e8b066390f279aebb175778086f6b7e4514
Campaign lock V2	63f9c337986b3d4cfaf20c1745df85e2cfd36a95e7557e894decc781e87646b0
Split manifest	bc2c7c8c72a14968c402cbb06fc0eebdde57a8b00a5ac5c88962716f06024160
Runtime	Python 3.11.9; torch 2.2.1+cu121; torchvision 0.17.1+cu121; CUDA

Thành phần khóa	Định danh / SHA-256
Training seeds	42, 123, 2026

Bảng 4b. Các khóa cần công bố để tái lập campaign.

4.4 Diễn biến hội tụ của 18 run

Mô hình	Seed	Epoch head / fine-tune	Checkpoint tốt nhất	Cảnh báo budget
MobileNetV2	42	15 / 30	finetune 29	Best trước epoch cuối
MobileNetV2	123	15 / 25	finetune 20	Best trước epoch cuối
MobileNetV2	2026	15 / 30	finetune 30	Best ở epoch fine-tune cuối
MobileNetV3-Large	42	15 / 19	finetune 14	Best trước epoch cuối
MobileNetV3-Large	123	15 / 24	finetune 19	Best trước epoch cuối
MobileNetV3-Large	2026	15 / 17	finetune 12	Best trước epoch cuối
ResNet-18	42	15 / 30	finetune 28	Best trước epoch cuối
ResNet-18	123	15 / 30	finetune 29	Best trước epoch cuối
ResNet-18	2026	14 / 30	finetune 26	Best trước epoch cuối
EfficientNet-B0	42	15 / 27	finetune 22	Best trước epoch cuối
EfficientNet-B0	123	15 / 29	finetune 24	Best trước epoch cuối
EfficientNet-B0	2026	15 / 30	finetune 29	Best trước epoch cuối
ShuffleNet V2 1.0×	42	15 / 30	finetune 30	Best ở epoch fine-tune cuối
ShuffleNet V2 1.0×	123	15 / 27	finetune 22	Best trước epoch cuối
ShuffleNet V2 1.0×	2026	15 / 30	finetune 26	Best trước epoch cuối
DenseNet-121	42	15 / 30	finetune 25	Best trước epoch cuối
DenseNet-121	123	15 / 30	finetune 26	Best trước epoch cuối
DenseNet-121	2026	13 / 30	finetune 30	Best ở epoch fine-tune cuối

Bảng 4c. Mọi checkpoint tốt nhất đều nằm ở fine-tune; ba run đạt best đúng epoch fine-tune cuối nên chưa đủ bằng chứng rằng mọi backbone đã hội tụ hoàn toàn.

Ba trường hợp MobileNetV2–2026, ShuffleNet V2–42 và DenseNet-121–2026 đạt best validation Macro-F1 đúng epoch fine-tune cuối. Vì vậy common budget vẫn là một giới hạn công bằng theo ngân sách, không phải bằng chứng rằng mỗi kiến trúc đã đạt tối ưu riêng; mô hình hội tụ chậm có thể bị bất lợi.

> Audit nuance: full hash verification 65.516/65.516 ảnh được chạy trước V2 trên cùng manifest; V2 lock khóa SHA của report đó. Report preflight mang provenance contract V1, nên cách viết chính xác là “report kiểm tra cùng manifest được V2 lock tham chiếu”, không phải “report được sinh trực tiếp từ V2 contract”.

5. Quy trình mở test và thước đo đánh giá

5.1 Quy trình test khóa

Script huấn luyện chỉ nạp train/validation. Script final_evaluate_v2.py tách riêng và trước khi mở test đã xác minh đủ 18 manifest complete, test_evaluated=false, provenance model/seed/contract/split/lock khớp và SHA-256 của checkpoint khớp.

Mốc audit	UTC	Ý nghĩa
Mở test	2026-08-30T07:03:50.506803+00:00	Guard chấp nhận cụm unlock I_UNDERSTAND_TEST_IS_FINAL
Hoàn tất	2026-08-30T07:10:31.355322+00:00	18 metrics JSON + 18 predictions CSV + aggregate/paired bootstrap
Trạng thái	complete	Mỗi CSV đúng 9.829 hàng; mọi confusion matrix tổng 9.829

Bảng 5. Audit mở test. Cơ chế là procedural guard; không phải khóa mật mã không thể chạy lại.

5.2 Định nghĩa metric

Thước đo	Công thức	Câu hỏi được trả lời
Accuracy	$(\Sigma^{c}{}_{c=1}\ TP_c) / N$	Bao nhiêu ảnh được phân loại đúng trên toàn bộ test?
Precision lớp c	$TP_c / (TP_c + FP_c)$	Trong các ảnh dự đoán là lớp c, bao nhiêu ảnh đúng?
Recall lớp c	$TP_c / (TP_c + FN_c)$	Trong các ảnh thật sự thuộc lớp c, mô hình tìm được bao nhiêu?
F1 lớp c	$2 \cdot Precision_c \cdot Recall_c / (Precision_c + Recall_c)$	Mức cân bằng giữa precision và recall của lớp c?
Macro-F1	$(1/C) \cdot \Sigma^{c}{}_{c=1}\ F1_c;\ C = 19$	Chất lượng trung bình khi mỗi lớp có trọng số bằng nhau?
Sample SD qua seed	$\sqrt{[\Sigma^{n}{}_{i=1}(x_i - \bar{x})^2 / (n-1)]};\ n = 3$	Kết quả thay đổi bao nhiêu giữa ba lần huấn luyện?

Bảng 5a. Công thức dùng đúng theo mã đánh giá; nếu mẫu số bằng 0, implementation đặt precision/recall/F1 tương ứng bằng 0.

Macro averaging cho mỗi lớp trọng số bằng nhau, vì vậy phù hợp làm endpoint chính khi class support mất cân bằng [8], [9]. Accuracy vẫn hữu ích để mô tả tổng số ảnh đúng, nhưng có thể bị ba lớp lớn chi phối.

5.3 Hai nguồn bất định không được trộn

- Mean ± sample SD qua 3 training seed mô tả biến thiên do huấn luyện. Với n=3, đây là thống kê mô tả, không phải 95% CI. Việc báo nhiều lần chạy tránh phụ thuộc một seed may mắn [11], [12].
- Bootstrap 2.000 mẫu trên ảnh test ước lượng sampling uncertainty có điều kiện trên checkpoint cố định; dùng percentile 2,5%–97,5% [10].
- Paired bootstrap giữ cặp dự đoán trên cùng ảnh nhưng chỉ thực hiện MobileNetV3-Large so với từng model, riêng theo seed. probability_delta_gt_zero là tỷ lệ bootstrap Δ>0, không phải p-value hay posterior probability.

Không được báo các chỉ số chưa tính: Weighted-F1, balanced accuracy, ROC-AUC, specificity, calibration/ECE, FLOPs, latency, năng lượng hoặc peak RAM. Chúng chỉ có thể xuất hiện trong mục "cần đo tiếp".

5.4 Cách đọc và giới hạn của từng bằng chứng

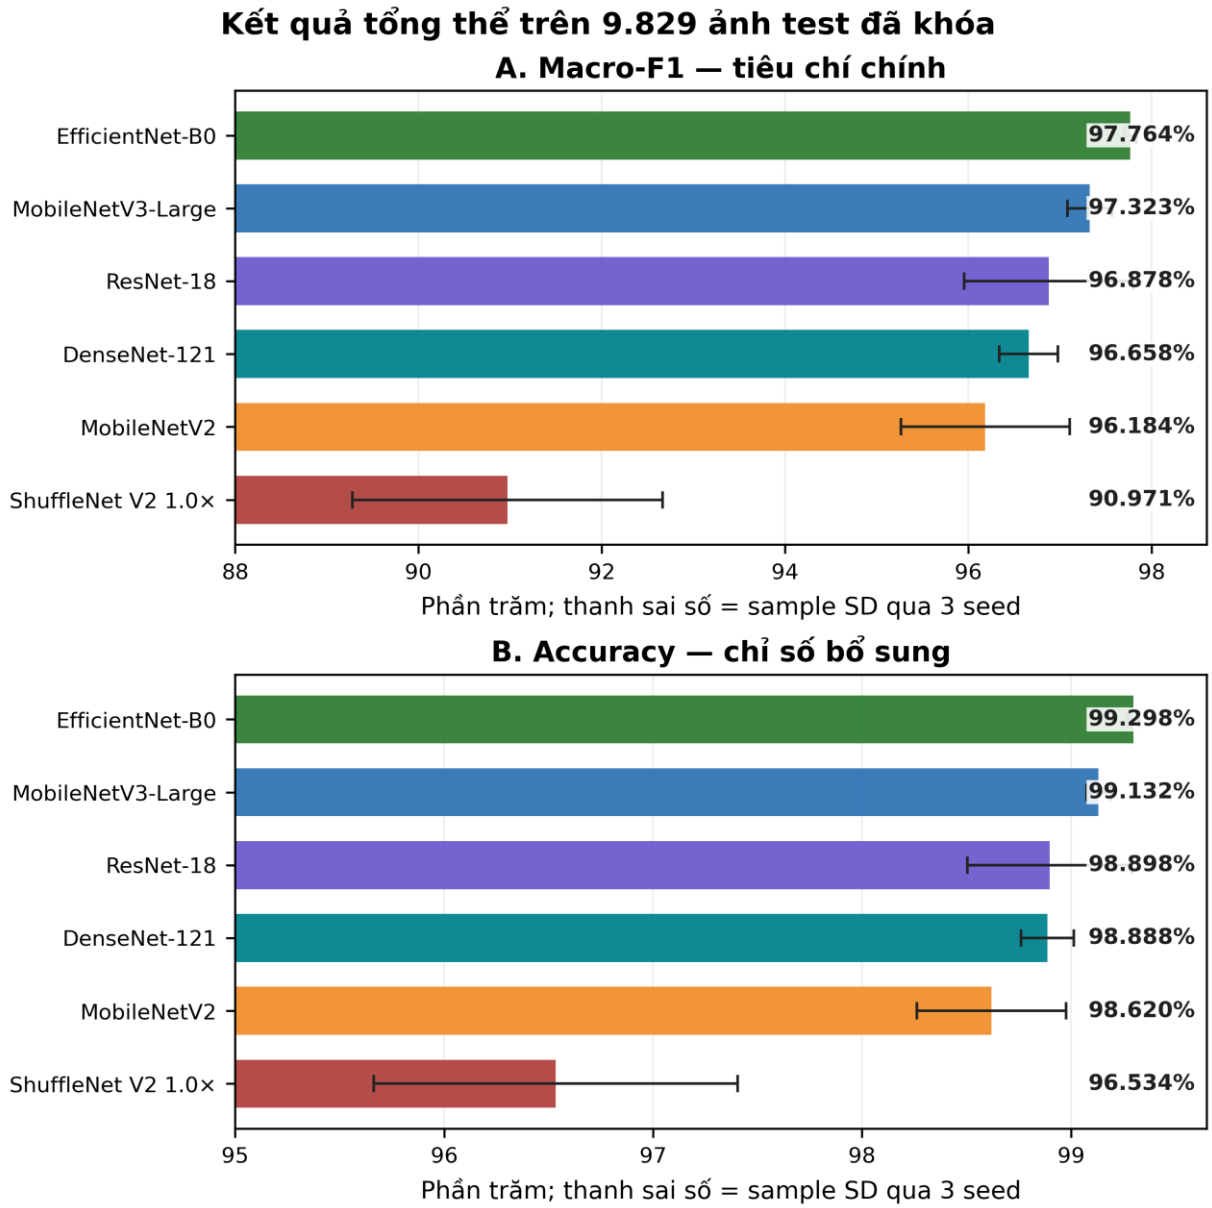
Bằng chứng	Dùng để trả lời	Không được suy ra
Mean Macro-F1	Chất lượng cân bằng qua 19 lớp	Ý nghĩa thống kê hoặc tổng quát ngoài split
Accuracy	Tỷ lệ đúng trên 9.829 ảnh	Chất lượng tốt ở lớp hiếm
Precision / Recall theo lớp	Dương tính giả và bỏ sót của từng nhãn	Nguyên nhân lỗi nếu chưa audit ảnh/nhãn
Sample SD qua 3 seed	Biến thiên do ba lần huấn luyện	CI95; phân phối đầy đủ của seed
Bootstrap ảnh test	Bất định lấy mẫu có điều kiện trên checkpoint	Bất định huấn luyện; p-value; posterior probability
Số tham số / checkpoint	Quy mô mạng và file PyTorch	FLOPs, latency, RAM, pin hoặc kích thước APK

Bảng 5b. Khung diễn giải bắt buộc để tránh trộn các nguồn bất định hoặc suy diễn quá dữ liệu.

Nội dung dùng làm thước đo	Nguồn phương pháp	Vai trò trong báo cáo
Precision, recall, F1, macro averaging	Sokolova & Lapalme [8]; scikit-learn [9]	Định nghĩa metric và cách đọc theo lớp
Bootstrap percentile	Efron & Tibshirani [10]	CI lấy mẫu ảnh test và paired delta
Báo phân bố qua nhiều lần chạy	Reimers & Gurevych [11]; Bouthillier et al. [12]	Báo từng seed, mean và sample SD
Tách chọn model khỏi đánh giá cuối	Cawley & Talbot [13]	Không dùng final test để tuning
Giới hạn tái lập theo nền tảng	PyTorch official docs [14]	Không hứa bitwise reproducibility qua máy/release

Bảng 5c. Các link URL/DOI bấm được được in đầy đủ ở mục Tài liệu tham khảo.

6. Kết quả tổng thể và độ ổn định qua seed



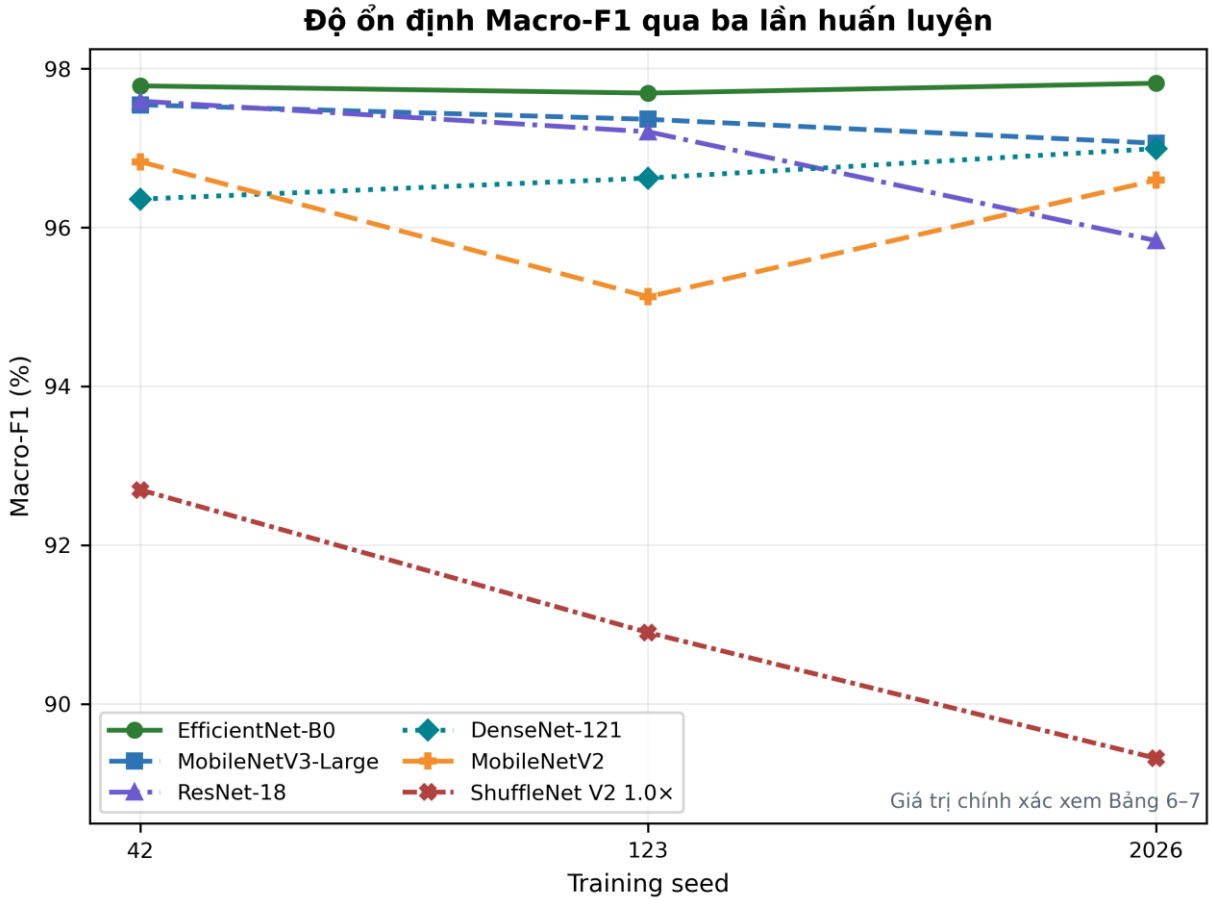
Hình 1. Mean Macro-F1 và Accuracy trên hai panel xếp dọc; thanh sai số là sample SD qua ba training seed.

Mô hình	Accuracy	Macro-P	Macro-R	Macro-F1	Khoảng seed F1
EfficientNet-B0	99.298 ± 0.027	97.534 ± 0.079	98.033 ± 0.053	97.764 ± 0.064	0.124 đ.%
MobileNetV3-Large	99.132 ± 0.058	97.231 ± 0.361	97.456 ± 0.152	97.323 ± 0.244	0.483 đ.%
ResNet-18	98.898 ± 0.394	96.628 ± 1.004	97.205 ± 0.802	96.878 ± 0.923	1.756 đ.%
DenseNet-121	98.888 ± 0.126	96.240 ± 0.378	97.151 ± 0.235	96.658 ± 0.320	0.636 đ.%
MobileNetV2	98.620 ± 0.357	95.632 ± 1.100	96.908 ± 0.635	96.184 ± 0.922	1.701 đ.%
ShuffleNet V2 1.0×	96.534 ± 0.871	89.985 ± 1.529	93.063 ± 1.474	90.971 ± 1.691	3.379 đ.%

Bảng 6. Kết quả tổng hợp (%). Mỗi ô metric trình bày mean ± sample SD qua 3 seed.

EfficientNet-B0 đứng đầu đồng thời ở Accuracy, Macro-Precision, Macro-Recall và Macro-F1. Mean Macro-F1 97,764% cao hơn MobileNetV3-Large 0,441 điểm %, ResNet-18 0,887 điểm %, DenseNet-121 1,107 điểm %, MobileNetV2 1,580 điểm % và ShuffleNet V2 6,793 điểm %.

Khoảng seed của EfficientNet-B0 chỉ 0,124 điểm %, nhỏ nhất trong sáu model. MobileNetV3-Large cũng ổn định (0,483 điểm %). Ngược lại ShuffleNet V2 có khoảng 3,379 điểm % và sample SD 1,691 điểm %, cho thấy kết quả nhạy seed nhất trong protocol này.



Hình 2. Macro-F1 của từng seed. EfficientNet-B0 đứng đầu cả ba; ShuffleNet V2 đứng cuối cả ba.

6.1 Kết quả từng seed

Seed	#1	#2	#3	#4	#5	#6
42	Eff-B0 97.784%	RN18 97.592%	MV3-L 97.545%	MV2 96.829%	DN121 96.357%	Shuffle 92.696%
123	Eff-B0 97.693%	MV3-L 97.363%	RN18 97.206%	DN121 96.622%	MV2 95.128%	Shuffle 90.899%
2026	Eff-B0 97.817%	MV3-L 97.062%	DN121 96.993%	MV2 96.596%	RN18 95.835%	Shuffle 89.317%

Bảng 7. Xếp hạng theo từng seed; không chọn "best seed" làm kết quả chính.

6.2 Mức chênh thực tế, thứ hạng và cân bằng precision–recall

Mô hình	Đúng / sai: seed 42	Đúng / sai: seed 123	Đúng / sai: seed 2026	Hạng F1	Macro-R – Macro-P
EfficientNet-B0	9757 / 72	9762 / 67	9761 / 68	1/1/1	+0.499 đ.%
MobileNetV3-Large	9750 / 79	9742 / 87	9739 / 90	3/2/2	+0.225 đ.%
ResNet-18	9742 / 87	9744 / 85	9676 / 153	2/3/5	+0.577 đ.%
DenseNet-121	9712 / 117	9713 / 116	9734 / 95	5/4/3	+0.910 đ.%
MobileNetV2	9717 / 112	9653 / 176	9710 / 119	4/5/4	+1.276 đ.%
ShuffleNet V2 1.0×	9576 / 253	9484 / 345	9405 / 424	6/6/6	+3.078 đ.%

Bảng 7a. Mỗi seed dự đoán cùng 9.829 ảnh. "Hạng F1" lần lượt ứng với seed 42/123/2026.

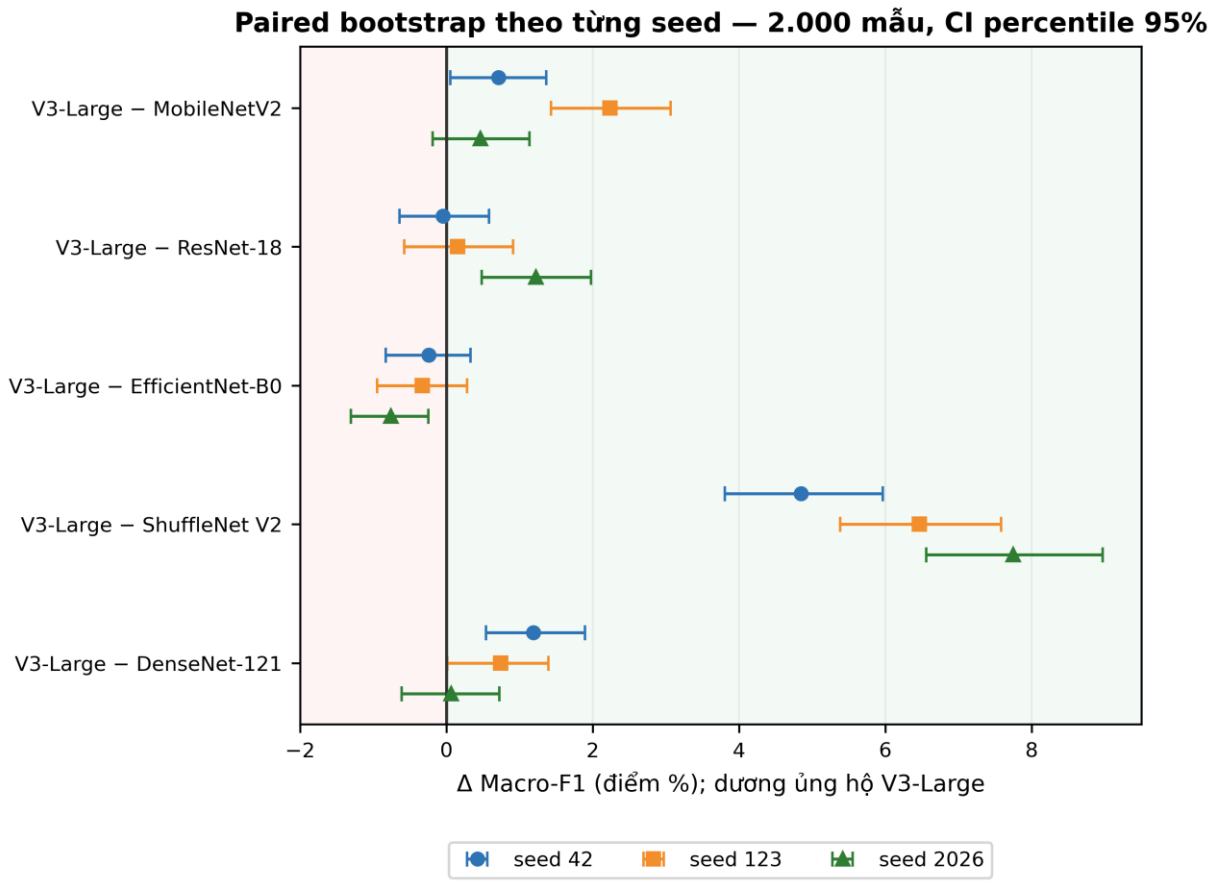
EfficientNet-B0 tạo trung bình 69.0 quyết định sai/run, còn MobileNetV3-Large 85.3; chênh khoảng 16.3 ảnh/run. Tuy nhiên chênh Macro-F1 giữa hai model là 0,441 điểm %, lớn hơn chênh Accuracy vì Macro-F1 cho mỗi lớp trọng số bằng nhau và phản ánh rõ hơn chất lượng ở lớp nhỏ.

Macro-Recall cao hơn Macro-Precision ở cả sáu mô hình. Chênh lớn nhất thuộc ShuffleNet V2 1.0× (3.078 điểm %), gợi ý dương tính giả đáng chú ý ở một số lớp. Đây là mô tả error profile; không được quy nguyên nhân cho weighted loss nếu chưa có ablation loss.

6.3 Validation–test gap nội bộ

Cả 18 checkpoint có test Macro-F1 thấp hơn best validation Macro-F1. Mean gap theo mô hình lần lượt là Eff-B0 -0.744 điểm %; MV3-L -0.526 điểm %; RN18 -0.879 điểm %; DN121 -1.307 điểm %; MV2 -0.554 điểm %; Shuffle -1.498 điểm %. Đây là chênh lệch nội bộ giữa checkpoint đã chọn trên validation và test cố định; có thể chứa selection optimism hoặc khác biệt lấy mẫu, nhưng không tự chứng minh overfitting nhân quả.

7. So sánh bất định bằng paired bootstrap



Hình 3. Chênh lệch Macro-F1 MobileNetV3-Large trừ mô hình đối chiếu; CI95 theo từng seed.

7.1 Cách đọc forest plot

Dấu / vị trí CI	Diễn giải được phép	Không được viết
Δ > 0	Checkpoint V3-Large có Macro-F1 quan sát cao hơn đối chiếu	V3 tốt hơn tuyệt đối
CI hoàn toàn dương	Bất định lấy mẫu ảnh test trong run ủng hộ V3	Ý nghĩa thống kê tổng thể qua seed
CI chứa 0	Dữ liệu test/run chưa tách biệt rõ hai checkpoint	Hai model tương đương
CI hoàn toàn âm	Bất định lấy mẫu ảnh test trong run ủng hộ đối chiếu	Đối chiếu thắng trên mọi domain

Bảng 8a. Pairing nằm ở dự đoán của hai checkpoint trên cùng ảnh test; không phải pairing của quá trình huấn luyện.

Cùng số seed giữa hai kiến trúc không biến chúng thành hai training replicate được ghép cặp. Việc ghép cặp chỉ xuất hiện khi resample cùng 9.829 ảnh và lấy chênh lệch metric của hai vector dự đoán. Có 15 contrast (5 đối chiếu × 3 seed), chưa hiệu chỉnh multiplicity và chưa có mô hình phân cấp gộp seed.

Đối chiếu	Seed	Δ F1 (đ.%)	CI95 (đ.%)	Tỷ lệ Δ>0	Đọc đúng
V3 – MobileNetV2	42	+0.716	[+0.054; +1.366]	0.9825	CI loại 0
V3 – MobileNetV2	123	+2.235	[+1.432; +3.068]	1.0000	CI loại 0
V3 – MobileNetV2	2026	+0.466	[-0.187; +1.136]	0.9095	CI chứa 0
V3 – ResNet-18	42	-0.046	[-0.640; +0.582]	0.4435	CI chứa 0
V3 – ResNet-18	123	+0.157	[-0.575; +0.913]	0.6590	CI chứa 0
V3 – ResNet-18	2026	+1.227	[+0.482; +1.978]	1.0000	CI loại 0
V3 – EfficientNet-B0	42	-0.239	[-0.830; +0.332]	0.2070	CI chứa 0
V3 – EfficientNet-B0	123	-0.330	[-0.945; +0.285]	0.1405	CI chứa 0
V3 – EfficientNet-B0	2026	-0.755	[-1.300; -0.245]	0.0035	CI loại 0
V3 – ShuffleNet V2	42	+4.849	[+3.807; +5.967]	1.0000	CI loại 0
V3 – ShuffleNet V2	123	+6.463	[+5.382; +7.583]	1.0000	CI loại 0
V3 – ShuffleNet V2	2026	+7.745	[+6.560; +8.970]	1.0000	CI loại 0
V3 – DenseNet-121	42	+1.188	[+0.540; +1.893]	1.0000	CI loại 0
V3 – DenseNet-121	123	+0.740	[+0.014; +1.397]	0.9760	CI loại 0
V3 – DenseNet-121	2026	+0.069	[-0.607; +0.725]	0.5775	CI chứa 0

Bảng 8b. Paired bootstrap 2.000 mẫu/đối chiếu/seed. Không có hiệu chỉnh multiple comparisons và không có phép gộp ba seed.

MobileNetV3-Large hơn MobileNetV2 ở cả ba giá trị quan sát; CI loại 0 ở seed 42 và 123 nhưng chứa 0 ở seed 2026. So với ShuffleNet V2, V3 hơn rõ ở cả ba seed với CI hoàn toàn dương. So với ResNet-18, dấu và độ chắc chắn không đồng nhất: seed 42 hơi nghiêng về ResNet, seed 123 gần nhau, seed 2026 ủng hộ V3.

EfficientNet-B0 có observed Macro-F1 cao hơn V3 ở cả ba seed. Tuy nhiên CI của V3−EffB0 chỉ hoàn toàn âm ở seed 2026; hai seed còn lại chứa 0. Do không có mô hình phân cấp hoặc kiểm định gộp qua seed, báo cáo chỉ kết luận "EfficientNet-B0 có mean cao hơn và thắng quan sát ở cả ba seed", không tuyên bố significance tổng thể.

8. Phân tích sâu từng mô hình

8.1 EfficientNet-B0

Kết quả: #1 theo mean Macro-F1 (97,764% ± 0,064%), Accuracy 99,298% ± 0,027%; đứng đầu cả ba seed.

Ổn định: range seed chỉ 0,124 điểm %, nhỏ nhất campaign. Đây là bằng chứng mô tả mạnh nhất về độ ổn định huấn luyện trong sáu model, dù n=3 còn nhỏ.

Lớp khó: downy_mildew 92,939%, tungro 94,142%, blast 94,946%, weeds 95,149%. Đây là kết quả cân bằng tốt nhất hoặc gần tốt nhất ở nhóm lớp khó.

Kiến trúc: compound scaling/MBConv là cơ chế hợp lý để giải thích hiệu quả phân bổ capacity [4], nhưng campaign không có ablation nên không chứng minh quan hệ nhân quả.

Triển khai: 4,032 triệu tham số và checkpoint 15,67 MiB; thậm chí ít tham số hơn V3-Large nhưng không được suy ra latency thấp hơn nếu chưa benchmark runtime chung.

8.2 MobileNetV3-Large

Kết quả: #2, Macro-F1 97,323% ± 0,244%, Accuracy 99,132% ± 0,058%; kém EfficientNet-B0 0,441 điểm % theo mean.

Lớp khó: weeds 95,563% là cao nhất trong sáu model theo mean; downy_mildew 91,909%, tungro 93,071%, blast 94,054%.

Kiến trúc: hardware-aware NAS, NetAdapt, SE và hard-swish được thiết kế cho accuracy–latency trade-off trên mobile [2]. Đây là cơ sở chọn ứng viên sản phẩm, không thay phép đo trên OPPO A54.

Bất định: paired bootstrap không cho thấy V3 chắc chắn hơn EfficientNet ở cấp model tổng thể; V3 hơn Shuffle nhất quán và hơn MobileNetV2 rõ ở 2/3 seed.

Triển khai: 4,226 triệu tham số, checkpoint 16,32 MiB; cần TFLite/ONNX conversion đồng nhất trước benchmark.

8.3 ResNet-18

Kết quả: #3, Macro-F1 96,878% ± 0,923%; seed 42 đạt 97,592% nhưng seed 2026 giảm còn 95,835%.

Ổn định: SD cao thứ hai sau ShuffleNet; vì vậy một run ResNet đẹp có thể gây kết luận quá lạc quan nếu không chạy nhiều seed.

Kiến trúc: residual shortcut hỗ trợ tối ưu mạng sâu [3], nhưng ResNet-18 không được thiết kế đặc biệt cho mobile.

Tài nguyên: 11,186 triệu tham số và checkpoint 42,75 MiB, lớn nhất campaign. Dù chất lượng khá cao, tỷ lệ chất lượng–quy mô kém hơn EfficientNet/V3.

Lưu ý: không có paired bootstrap ResNet với EfficientNet hoặc DenseNet; không được nói #3 có ý nghĩa thống kê so với #4.

8.4 DenseNet-121

Kết quả: #4, Macro-F1 96,658% ± 0,320%, chỉ thấp hơn ResNet-18 0,220 điểm % theo mean.

Lớp: leaf_smut 94,500% là cao nhất theo mean trong sáu model; tungro 93,284% và bacterial_leaf_streak 92,841%.

Ổn định: tốt hơn ResNet-18/MobileNetV2/ShuffleNet theo SD; xu hướng tăng đều từ seed 42 đến 2026 chỉ là mô tả, không phải quan hệ với giá trị seed.

Kiến trúc: dense connectivity giúp feature propagation/reuse [6]; có thể phù hợp tổn thương đa mức, nhưng concatenate feature map có chi phí bộ nhớ chưa đo.

Tài nguyên: 6,973 triệu tham số, checkpoint 27,18 MiB và thời gian train ghi nhận dài nhất; training time không phải inference latency.

8.5 MobileNetV2

Kết quả: #5, Macro-F1 96,184% ± 0,922%; seed 123 thấp hơn rõ so với hai seed còn lại.

So với V3: V3 tăng mean Macro-F1 1,139 điểm % và observed delta dương ở cả ba seed; đây là bằng chứng hợp lý để nâng backbone mobile từ V2 lên V3.

Kiến trúc: inverted residual và linear bottleneck tạo baseline mobile gọn [1], nhưng trong bài toán 19 lớp này capacity/attention có thể hạn chế phân biệt tổn thương gần nhau.

Lớp khó: downy_mildew 86,516%, tungro 89,403%, weeds 90,811%; là các điểm cần xem khi dùng V2 làm bản Basic.

Tài nguyên: 2,248 triệu tham số, checkpoint 8,81 MiB. Nhỏ hơn V3/EfficientNet nhưng chưa đủ để kết luận trải nghiệm mobile tốt hơn.

8.6 ShuffleNet V2 1.0×

Kết quả: #6, Macro-F1 90,971% ± 1,691%; thấp hơn model #5 MobileNetV2 5,213 điểm % và biến thiên lớn nhất.

Lớp khó: bacterial_leaf_streak 71,217%, downy_mildew 74,558%, tungro 75,876%, blast 79,901%, weeds 81,939%.

Diễn giải: kết quả cho thấy cấu hình 1.0× dưới common recipe có thể thiếu capacity/độ ổn định cho lớp hình thái gần; chưa chứng minh mọi biến thể ShuffleNet đều yếu.

Tài nguyên: nhỏ nhất, 1,273 triệu tham số và checkpoint 5,02 MiB; đây là đầu Pareto về quy mô nhưng phải đánh đổi chất lượng đáng kể.

Tốc độ: paper ShuffleNet V2 nhấn mạnh actual speed phụ thuộc memory access/platform [5]; không được gọi đây là model nhanh nhất nếu chưa đo.

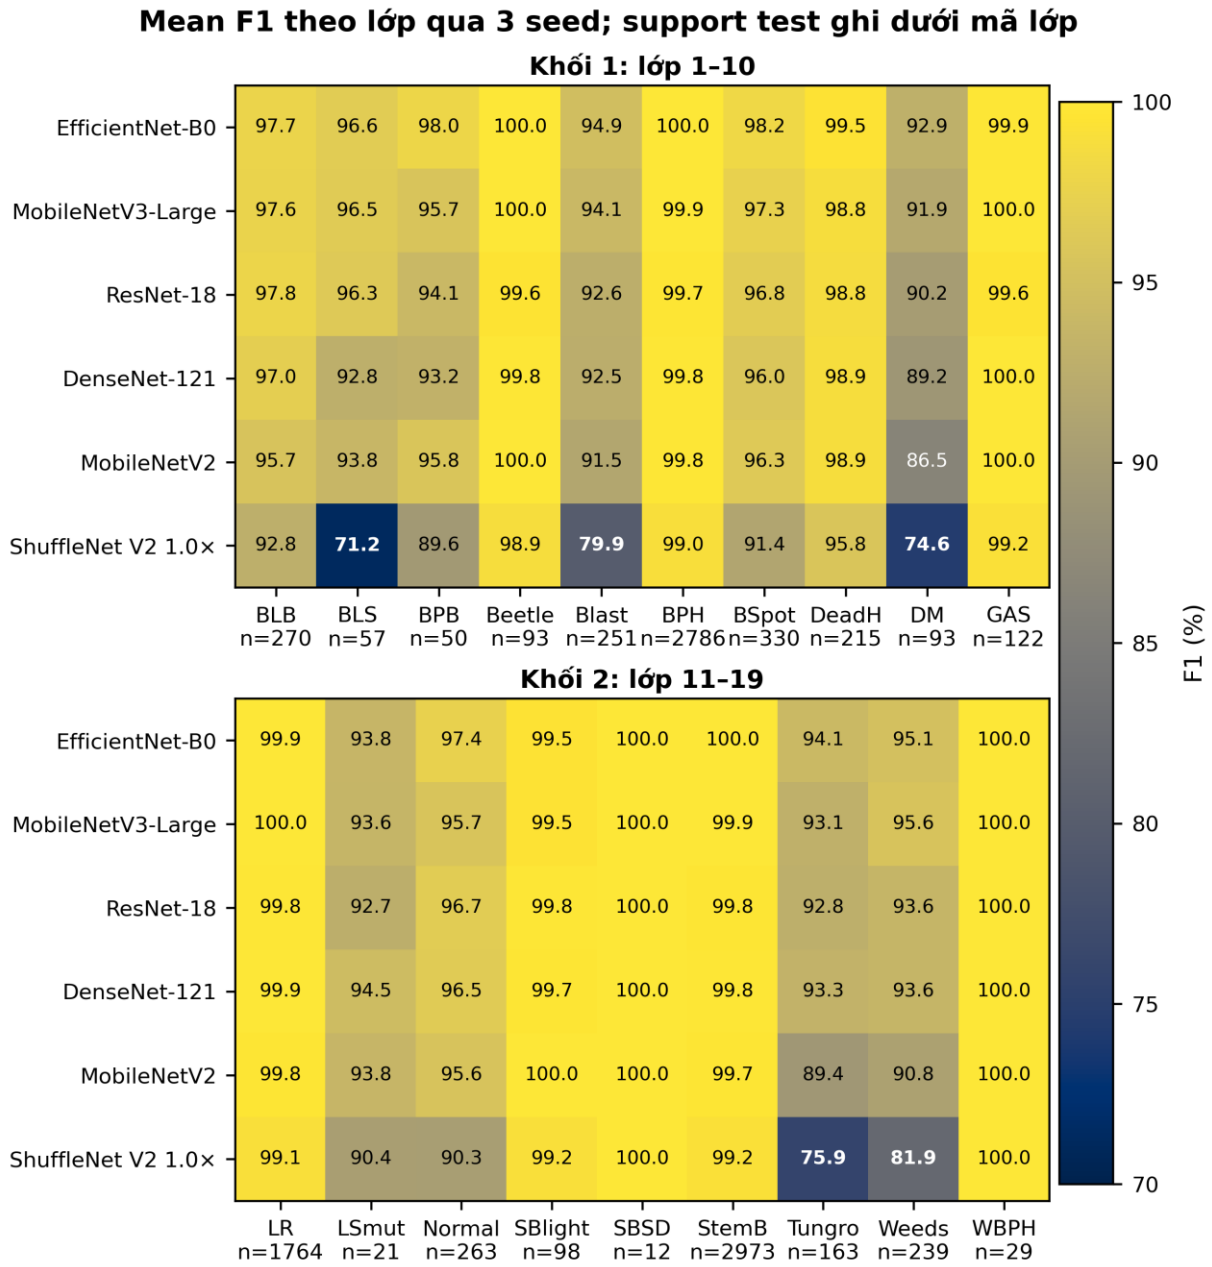
8.7 Bảng chẩn đoán chéo sáu mô hình

Mô hình	Macro-P / Macro-R	Lớp F1 thấp nhất	Lớp bất ổn nhất	Nhầm lẫn nhiều nhất / 3 seed
EfficientNet-B0	97.53 / 98.03	downy_mildew 92.94%	bacterial_leaf_streak SD 2.51 đ.%	blast → tungro: 22
MobileNetV3-Large	97.23 / 97.46	downy_mildew 91.91%	bacterial_panicle_blight SD 1.44 đ.%	blast → tungro: 21
ResNet-18	96.63 / 97.21	downy_mildew 90.16%	downy_mildew SD 3.73 đ.%	blast → tungro: 21
DenseNet-121	96.24 / 97.15	downy_mildew 89.18%	bacterial_leaf_streak SD 2.83 đ.%	blast → tungro: 22
MobileNetV2	95.63 / 96.91	downy_mildew 86.52%	downy_mildew SD 3.85 đ.%	blast → downy_mildew: 30
ShuffleNet V2 1.0×	89.99 / 93.06	bacterial_leaf_streak 71.22%	bacterial_leaf_streak SD 7.96 đ.%	blast → tungro: 82

Bảng 8c. Số nhầm là tổng quyết định của ba seed trên cùng test, không phải số ảnh độc lập.

Error profile theo lớp cho thấy recall có thể cao nhưng precision thấp: ShuffleNet ở bacterial_leaf_streak đạt precision 56.14%, recall 98.83% và F1 71.22%; ở downy_mildew là 64.63% / 88.17% / 74.56%. MobileNetV2 ở downy_mildew cũng có precision 78.37% nhưng recall 96.77%. Điều này định vị dương tính giả, nhưng chưa xác định nguyên nhân nếu chưa audit ảnh và ablation loss.

9. Phân tích theo lớp và mẫu lỗi



Hình 4. Mean F1 của 19 lớp, tách thành hai khối để giữ cỡ chữ; mọi ô đều ghi giá trị và support.

Lớp (support)	Eff-B0	MV3-L	RN18	DN121	MV2	Shuffle
downy_mildew (n=93)	92.94 ± 0.84	91.91 ± 0.81	90.16 ± 3.73	89.18 ± 2.27	86.52 ± 3.85	74.56 ± 6.87
tungro (n=163)	94.14 ± 0.82	93.07 ± 0.48	92.79 ± 2.24	93.28 ± 1.01	89.40 ± 2.99	75.88 ± 4.92
blast (n=251)	94.95 ± 0.66	94.05 ± 0.82	92.64 ± 2.37	92.51 ± 0.41	91.53 ± 1.68	79.90 ± 3.87
weeds (n=239)	95.15 ± 0.78	95.56 ± 0.74	93.57 ± 2.27	93.56 ± 1.40	90.81 ± 2.27	81.94 ± 3.80
bacterial_leaf_streak (n=57)	96.62 ± 2.51	96.55 ± 0.89	96.34 ± 0.95	92.84 ± 2.83	93.84 ± 2.04	71.22 ± 7.96

Bảng 9. Năm lớp khó nhất; mỗi ô là mean ± sample SD F1 (%) qua 3 seed.

downy_mildew là lớp khó nhất toàn campaign. EfficientNet-B0 đạt mean 92,939%, V3-Large 91,909%, ResNet-18 90,156%, DenseNet-121 89,183%, MobileNetV2 86,516% và ShuffleNet 74,558%. Các khoảng cách này cho thấy năng lực phân biệt tổn thương hình thái gần là nơi kiến trúc tách nhau rõ hơn so với lớp lớn/dễ.

southern_black_streaked_dwarf (n=12) và whitebacked_planthopper (n=29) đạt 100% ở cả 18 run. Nhưng chỉ cần một ảnh sai sẽ làm recall thay đổi 8,33 hoặc 3,45 điểm %, nên 100% ở support thấp không đồng nghĩa bài toán đã giải quyết.

9.1 Mô hình dẫn đầu theo từng lớp

Lớp	Support	Mô hình có mean F1 cao nhất	Mean F1	Biên với mức kế tiếp
bacterial_leaf_blight	270	RN18	97.828%	0.098 đ.%
bacterial_leaf_streak	57	Eff-B0	96.619%	0.073 đ.%
bacterial_panicle_blight	50	Eff-B0	97.987%	2.188 đ.%
beetle	93	Eff-B0, MV3-L, MV2	100.000%	Đồng hạng
blast	251	Eff-B0	94.946%	0.893 đ.%
brown_planthopper	2786	Eff-B0	99.952%	0.060 đ.%
brown_spot	330	Eff-B0	98.175%	0.848 đ.%
dead_heart	215	Eff-B0	99.458%	0.544 đ.%
downy_mildew	93	Eff-B0	92.939%	1.030 đ.%
golden_apple_snail	122	MV3-L, DN121, MV2	100.000%	Đồng hạng
leaf_roller	1764	MV3-L	99.972%	0.028 đ.%
leaf_smut	21	DN121	94.500%	0.738 đ.%
normal	263	Eff-B0	97.409%	0.714 đ.%
sheath_blight	98	MV2	100.000%	0.171 đ.%
southern_black_streaked_dwarf	12	Eff-B0, MV3-L, RN18, DN121, MV2, Shuffle	100.000%	Đồng hạng
stem_borer	2973	Eff-B0	99.961%	0.034 đ.%
tungro	163	Eff-B0	94.142%	0.858 đ.%
weeds	239	MV3-L	95.563%	0.413 đ.%
whitebacked_planthopper	29	Eff-B0, MV3-L, RN18, DN121, MV2, Shuffle	100.000%	Đồng hạng

Bảng 9a. Mean metric được tính qua ba seed; biên không phải CI hay kiểm định theo lớp.

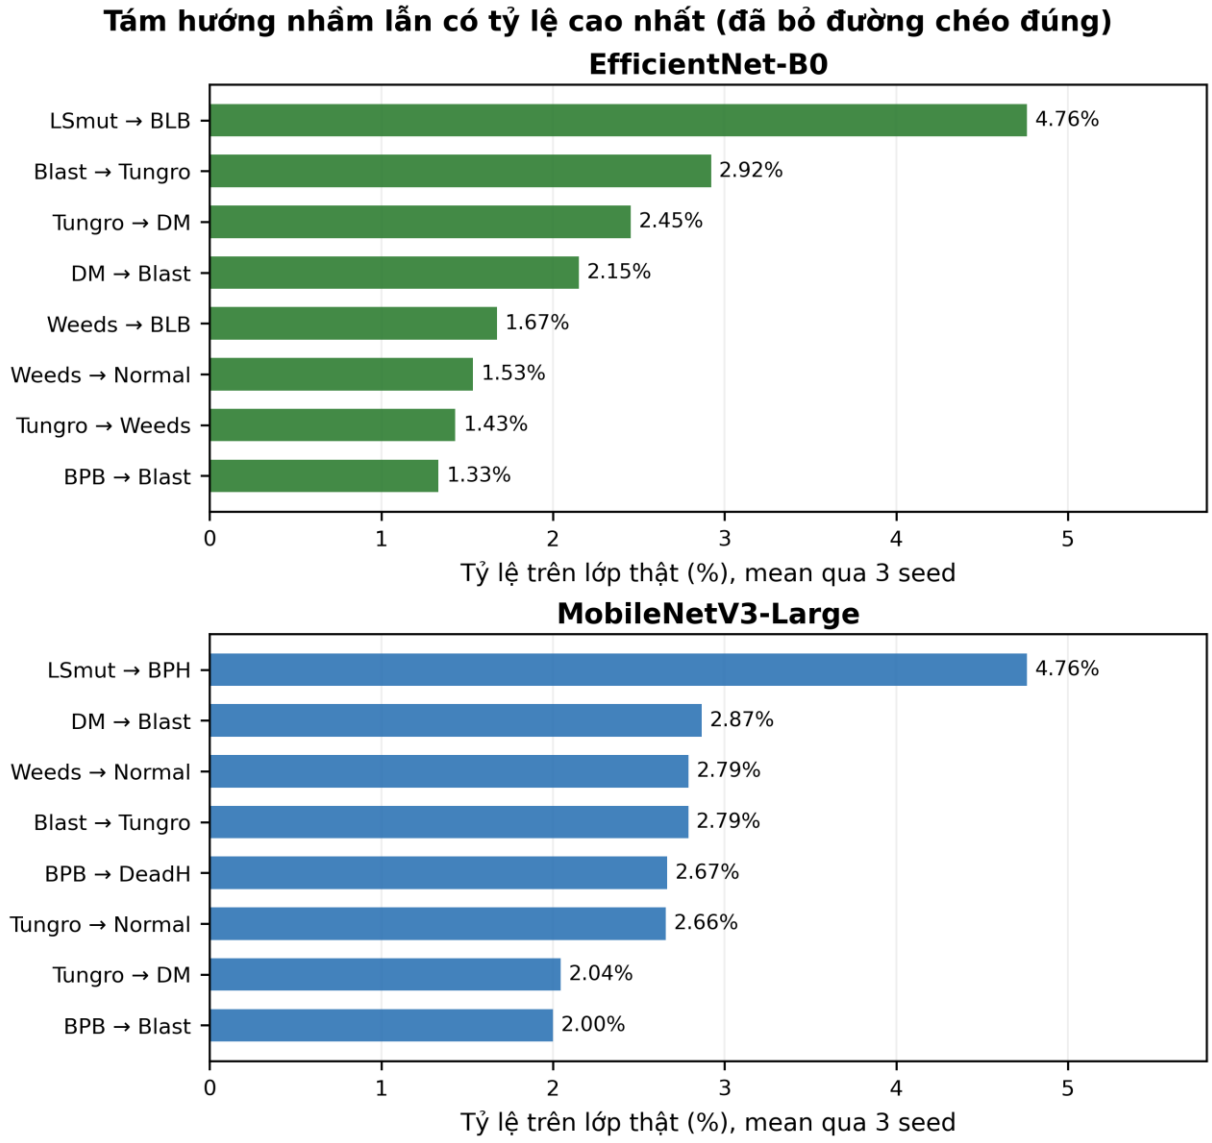
Số lớp có người thắng duy nhất: EfficientNet-B0 10; MobileNetV3-Large 2; ResNet-18 1; DenseNet-121 1; MobileNetV2 1. Bốn lớp còn lại có đồng hạng tuyệt đối, phần lớn do support thấp hoặc tất cả mô hình đều dự đoán đúng toàn bộ; vì vậy không gán điểm thắng tùy tiện cho model xuất hiện trước.

9.2 Bất ổn theo lớp qua seed

Mô hình	Lớp có SD F1 lớn nhất	Support	Mean F1	Sample SD F1
EfficientNet-B0	bacterial_leaf_streak	57	96.619%	2.506 đ.%
MobileNetV3-Large	bacterial_panicle_blight	50	95.669%	1.442 đ.%
ResNet-18	downy_mildew	93	90.156%	3.727 đ.%
DenseNet-121	bacterial_leaf_streak	57	92.841%	2.828 đ.%
MobileNetV2	downy_mildew	93	86.516%	3.846 đ.%
ShuffleNet V2 1.0×	bacterial_leaf_streak	57	71.217%	7.961 đ.%

Bảng 9b. Aggregate ổn định có thể che bất ổn ở một lớp nhỏ; n=3 nên SD chỉ mang tính mô tả.

9.3 Mẫu nhầm lẫn



Hình 5. Tám hướng nhầm có tỷ lệ theo lớp thật cao nhất của EfficientNet-B0 và MobileNetV3-Large; đường chéo đúng đã được loại.

Nhãn thật	Dự đoán	Số quyết định sai / 3 seed × 6 model	Diễn giải
blast	tungro	190	Ưu tiên audit
stem_borer	brown_planthopper	119	Theo dõi
blast	downy_mildew	106	Ưu tiên audit
normal	weeds	106	Theo dõi
weeds	normal	98	Ưu tiên audit
weeds	downy_mildew	93	Ưu tiên audit

Nhãn thật	Dự đoán	Số quyết định sai / 3 seed × 6 model	Diễn giải
brown_planthopper	stem_borer	77	Theo dõi
tungro	downy_mildew	69	Ưu tiên audit
stem_borer	leaf_roller	68	Theo dõi
weeds	blast	68	Ưu tiên audit
brown_spot	blast	67	Theo dõi
brown_spot	tungro	63	Theo dõi

Bảng 10. Tổng lỗi qua 18 run. Đây là số quyết định lặp lại, không phải số ảnh độc lập.

- Mẫu phổ biến: blast→tungro; weeds↔normal; tungro↔downy_mildew/blast; blast↔brown_spot/downy_mildew.
- Tổng repeated errors trên 3×9.829 quyết định/model: EfficientNet-B0 207; V3-Large 256; ResNet-18 325; DenseNet-121 328; MobileNetV2 407; ShuffleNet V2 1.022.

Mô hình	Ba hướng nhầm có tổng quyết định lớn nhất qua 3 seed
EfficientNet-B0	blast→tungro: 22; tungro→downy_mildew: 12; weeds→bacterial_leaf_blight: 12
MobileNetV3-Large	blast→tungro: 21; weeds→normal: 20; tungro→normal: 13
ResNet-18	blast→tungro: 21; stem_borer→brown_planthopper: 21; weeds→downy_mildew: 21
DenseNet-121	blast→tungro: 22; stem_borer→brown_planthopper: 17; brown_spot→blast: 14
MobileNetV2	blast→downy_mildew: 30; weeds→normal: 26; blast→tungro: 22
ShuffleNet V2 1.0×	blast→tungro: 82; normal→weeds: 55; brown_planthopper→stem_borer: 50

Bảng 10a. Error signature riêng từng mô hình; đơn vị là quyết định lặp lại trên cùng tập ảnh.

9.4 Ảnh sai nhất quán

Có 11 ảnh bị cả 18 tổ hợp model×seed dự đoán sai. Đây là ứng viên audit chất lượng ảnh/nhãn hoặc trường hợp hình thái đặc biệt; không phải bằng chứng tự động rằng nhãn sai.



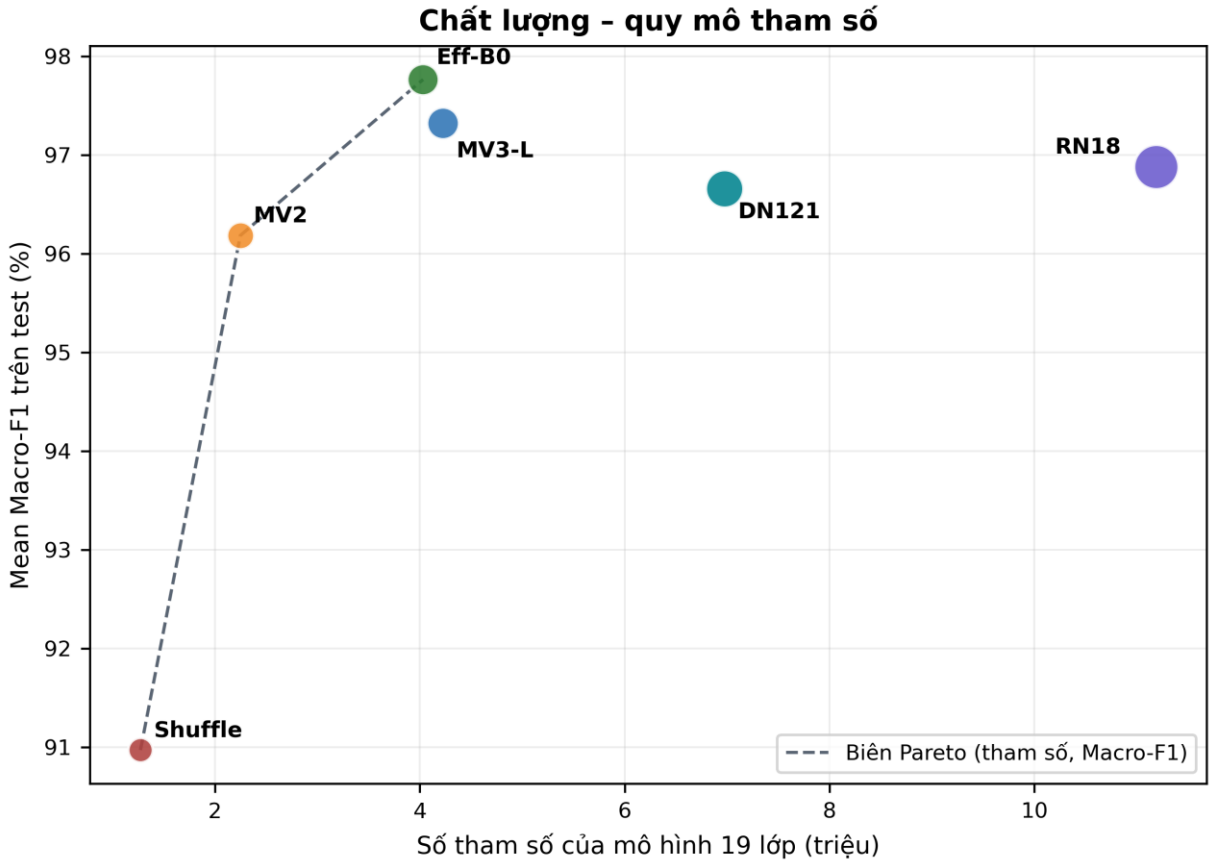
Hình 6. Error atlas của 11 ảnh sai ở toàn bộ 18 run; nhãn thật và phân bố dự đoán được ghi dưới mỗi ảnh.

Ảnh	Nhãn thật	Các dự đoán phổ biến (số run)
blast_0241.jpg	blast	weeds:18
blast_0257.jpg	blast	normal:18
blast_0753.jpg	blast	tungro:18
blast_0946.jpg	blast	tungro:18

Ảnh	Nhãn thật	Các dự đoán phổ biến (số run)
blast_1002.jpg	blast	tungro:15; brown_spot:3
blast_1007.jpg	blast	tungro:18
blast_1067.jpg	blast	tungro:17; weeds:1
brown_spot_0035.jpg	brown_spot	leaf_smut:18
brown_spot_1741.jpg	brown_spot	bacterial_leaf_streak:18
tungro_0150.jpg	tungro	normal:18
tungro_0764.jpg	tungro	blast:10; downy_mildew:8

Bảng 11. Danh sách audit hậu nghiệm; không dùng để sửa test hoặc huấn luyện lại.

10. Hiệu quả tài nguyên và hàm ý triển khai mobile



Hình 7. Quan hệ mean Macro-F1 với số tham số; đường đứt thể hiện biên Pareto trên đúng hai trục này.

Mô hình	Tham số	Checkpoint	Train tổng 3 seed	Mean/run	Test−best val F1
EfficientNet-B0	4.031.887	15.666 MiB	9.880 h	3.293 h	-0.744 đ.%
MobileNetV3-Large	4.226.371	16.320 MiB	6.844 h	2.281 h	-0.526 đ.%
ResNet-18	11.186.259	42.749 MiB	7.388 h	2.463 h	-0.879 đ.%

Mô hình	Tham số	Checkpoint	Train tổng 3 seed	Mean/run	Test−best val F1
DenseNet-121	6.973.331	27.179 MiB	14.190 h	4.730 h	-1.307 đ.%
MobileNetV2	2.248.211	8.811 MiB	9.951 h	3.317 h	-0.554 đ.%
ShuffleNet V2 1.0×	1.273.079	5.023 MiB	5.764 h	1.921 h	-1.498 đ.%

Bảng 12. Thời gian train là số ghi trong manifest, bị ảnh hưởng bởi early stopping và tải máy; không phải inference latency.

10.1 Biên Pareto chỉ theo tham số và Macro-F1

Mô hình	Tham số	Mean Macro-F1	Trạng thái trong mặt phẳng 2D
ShuffleNet V2 1.0×	1.273.079	90.971%	Trên biên Pareto
MobileNetV2	2.248.211	96.184%	Trên biên Pareto
EfficientNet-B0	4.031.887	97.764%	Trên biên Pareto
MobileNetV3-Large	4.226.371	97.323%	Bị mô hình khác chi phối
DenseNet-121	6.973.331	96.658%	Bị mô hình khác chi phối
ResNet-18	11.186.259	96.878%	Bị mô hình khác chi phối

Bảng 12a. Biên Pareto thay đổi nếu thêm latency, RAM, năng lượng hoặc precision; các đại lượng đó chưa được đo.

Trong không gian hai mục tiêu “ít tham số hơn” và “Macro-F1 cao hơn”, EfficientNet-B0 chiếm ưu thế so với MobileNetV3-Large vì vừa ít tham số hơn vừa có mean F1 cao hơn. Tuy vậy V3 được thiết kế hardware-aware và có thể chạy nhanh hơn trên một số runtime; vì thế không được gọi EfficientNet là lựa chọn mobile tốt hơn trước khi đo latency/RAM/năng lượng.

EfficientNet-B0 có ít hơn MobileNetV3-Large 194.484 tham số (4,602%) và cao hơn 0,441 điểm % Macro-F1 trong campaign. Đây là dominance theo hai trục đã đo, không phải dominance triển khai. Checkpoint .pt chứa tensor/trạng thái PyTorch và cũng không bằng kích thước TFLite/ONNX/package cuối.

10.2 Quyết định Basic và Plus

Phiên bản	Backbone đề xuất	Giải thích	Điều kiện trước phát hành
Basic	MobileNetV3-Large + Grad-CAM chuẩn	V3 có chất lượng #2 và định hướng mobile; hiện tốt hơn V2 trong campaign	Benchmark cùng runtime; UX explainability tối giản; không tuyên bố calibrated confidence
Plus	MobileNetV3-Large + Hybrid CAM	Giữ cùng classifier để cô lập giá trị của phương pháp giải thích	Đánh giá localization/user study/runtime riêng; không trộn kết quả CAM với benchmark backbone
Ứng viên chất lượng	EfficientNet-B0	Mean Macro-F1 #1, ổn định nhất, quy mô gần V3	Chuyển đổi cùng precision và benchmark A/B trên OPPO A54

Bảng 13. Khuyến nghị sản phẩm hiện tại; quyết định cuối phụ thuộc benchmark mobile chuẩn hóa.

Benchmark mobile bắt buộc tiếp theo: cùng OPPO A54, cùng ảnh/input 224×224, batch=1, cùng runtime/delegate, cùng precision/quantization, cùng số thread, cùng warm-up; báo p50/p95/trimmed mean, peak PSS/RSS, năng lượng/nhiệt và kích thước package. Không so model bằng training time hoặc FLOPs đơn lẻ [5], [18].

11. Độ giá trị, giới hạn và nguy cơ sai lệch

Nguy cơ	Tác động	Cách viết / khắc phục
Split image-level	Ảnh tương quan cùng cây/ruộng/phiên có thể ở nhiều split	Chỉ kết luận nội bộ; xây group-aware split khi có metadata
Provenance thu thập/nhãn còn thiếu	Chưa xác minh đầy đủ địa điểm, thiết bị, thời gian và chuyên gia gán nhãn	Không gọi kết quả là xác nhận nông học/lâm sàng; bổ sung datasheet và audit chuyên gia
Không external test	Chưa biết domain shift theo vùng, mùa, thiết bị, ánh sáng	Thu thập field holdout độc lập theo không gian/thời gian
n=3 seed	SD ước lượng thô; không suy luận distribution mạnh	Báo từng seed + mean±sample SD; tăng seed nếu tài nguyên cho phép
Common recipe	Không phải cấu hình tối ưu riêng từng model	Kết luận “under common protocol”; có thể làm tuning budget công bằng ở nghiên cứu sau
Weight enum V1/V2	So sánh gồm cả pretrained checkpoint	Ghi rõ weight ID; không gọi là topology-only ablation
Class support cực thấp	F1/100% dễ biến động bởi 1 ảnh	Luôn báo support và CI; tăng dữ liệu lớp hiếm
Bootstrap iid ảnh	Không phản ánh clustering theo ruộng/cây	Dùng cluster/bootstrap hoặc grouped test khi có group ID
Không calibration	Softmax confidence không phải xác suất tin cậy	Đo ECE/Brier, reliability diagram và temperature scaling trên validation
Không mobile benchmark 6 model	Chưa kết luận latency/RAM/năng lượng	Benchmark cùng thiết bị/runtime sau conversion

Bảng 14. Threats to validity bắt buộc đưa vào bài báo.

11.1 Những gì campaign chứng minh

- Dưới một common recipe, cùng split nội bộ và cùng budget tối đa, EfficientNet-B0 có mean Macro-F1 cao nhất và biến thiên seed thấp nhất.
- MobileNetV3-Large tốt hơn MobileNetV2 về mean F1 và có lợi thế quan sát nhất quán ở ba seed; paired CI loại 0 ở hai seed.
- ShuffleNet V2 1.0× đánh đổi chất lượng lớn để đạt quy mô nhỏ trong cấu hình đã thử.

11.2 Những gì campaign chưa chứng minh

- Khả năng tổng quát ngoài thực địa, sang tỉnh/mùa/camera khác.
- Model nào nhanh/ít RAM/ít pin nhất trên Android.
- Hybrid CAM tốt hơn Grad-CAM về localization hoặc lòng tin người dùng.

- Confidence là xác suất đã hiệu chỉnh hoặc phù hợp quyết định nông nghiệp có rủi ro.
- EfficientNet-B0 tốt nhất tuyệt đối; ResNet chắc chắn hơn DenseNet; mọi biến thể ShuffleNet đều yếu.

12. Kết luận và khuyến nghị nghiên cứu

Campaign RiceAI V2 đã hoàn tất 18/18 run và mở test theo guard sau khi khóa contract/split/checkpoint. EfficientNet-B0 đạt kết quả tốt nhất trong phạm vi thí nghiệm: Accuracy 99,298% ± 0,027% và Macro-F1 97,764% ± 0,064%. MobileNetV3-Large đứng thứ hai với 97,323% ± 0,244%, đồng thời là ứng viên mobile hợp lý nhờ mục tiêu thiết kế hardware-aware. ResNet-18 và DenseNet-121 tạo nhóm giữa; MobileNetV2 là baseline mobile nhỏ nhưng kém V3; ShuffleNet V2 1.0× nhỏ nhất nhưng chịu giảm chất lượng và độ ổn định rõ.

Kết luận trung thực nhất không phải "model nào thắng tuyệt đối", mà là: EfficientNet-B0 tối ưu chất lượng nội bộ; MobileNetV3-Large có hồ sơ cân bằng tốt cho mobile nhưng cần xác nhận runtime; nhóm lớp downy_mildew/tungro/blast/weeds là nút thắt chất lượng; và giá trị ngoài thực địa vẫn phải được kiểm tra bằng grouped/external holdout.

12.1 Thứ tự công việc đề xuất

1. Đóng băng final_test_v2; không dùng test để điều chỉnh model/hyperparameter [13].
2. Tạo benchmark Android chung cho cả sáu model; nếu conversion khác nhau, ghi rõ runtime/delegate/precision.
3. Thu thập metadata cây–ruộng–phiên–thiết bị và tạo grouped external split.
4. Audit 11 ảnh sai nhất quán mà không thay đổi test hiện tại; kết quả audit chỉ dùng thiết kế dataset phiên bản mới.
5. Đánh giá calibration, abstention/uncertainty và threshold theo chi phí sai lầm nông nghiệp.
6. Thực hiện thí nghiệm Hybrid CAM vs Grad-CAM độc lập: localization, pointing game/IoU nếu có mask, thời gian sinh heatmap và user study.

Tài liệu tham khảo

Cách mở nguồn: trong Word desktop dùng Ctrl + nhấp vào URL màu xanh; trong Word mobile/Reading Mode chỉ cần chạm. URL/DOI thật được hiển thị để vẫn có thể sao chép nếu trình xem không hỗ trợ hyperlink DOCX.

[1] M. Sandler et al., "MobileNetV2: Inverted Residuals and Linear Bottlenecks," CVPR, 2018. doi: 10.1109/CVPR.2018.00474.
URL chính thức:
https://openaccess.thecvf.com/content_cvpr_2018/html/Sandler_MobileNetV2_Inverted_Residuals_CVPR_2018_paper.html

[2] A. Howard et al., "Searching for MobileNetV3," ICCV, 2019, pp. 1314–1324. doi: 10.1109/ICCV.2019.00140.
URL chính thức: https://openaccess.thecvf.com/content_ICCV_2019/html/Howard_Searching_for_MobileNetV3_ICCV_2019_paper.html

[3] K. He et al., "Deep Residual Learning for Image Recognition," CVPR, 2016. doi: 10.1109/CVPR.2016.90.
URL chính thức: https://openaccess.thecvf.com/content_cvpr_2016/html/He_Deep_Residual_Learning_CVPR_2016_paper.html

[4] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," ICML/PMLR 97, 2019, pp. 6105–6114.
URL chính thức: https://proceedings.mlr.press/v97/tan19a.html

[5] N. Ma et al., "ShuffleNet V2: Practical Guidelines for Efficient CNN Architecture Design," ECCV, 2018. doi: 10.1007/978-3-030-01264-9_8.
URL chính thức: https://openaccess.thecvf.com/content_ECCV_2018/html/Ningning_Light-weight_CNN_Architecture_ECCV_2018_paper.html

[6] G. Huang et al., "Densely Connected Convolutional Networks," CVPR, 2017. doi: 10.1109/CVPR.2017.243.
URL chính thức: https://openaccess.thecvf.com/content_cvpr_2017/html/Huang_Densely_Connected_Convolutional_CVPR_2017_paper.html

[7] Y. Cui et al., "Class-Balanced Loss Based on Effective Number of Samples," CVPR, 2019, pp. 9268–9277. doi: 10.1109/CVPR.2019.00949.
URL chính thức: https://openaccess.thecvf.com/content_CVPR_2019/html/Cui_Class-Balanced_Loss_Based_on_Effective_Number_of_Samples_CVPR_2019_paper.html

[8] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," Information Processing & Management, 45(4), 2009. doi: 10.1016/j.ipm.2009.03.002.
URL chính thức: https://doi.org/10.1016/j.ipm.2009.03.002

[9] Scikit-learn, "Precision, recall, F-measure and support" and "Confusion matrix," official documentation.
URL chính thức: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.precision_recall_fscore_support.html
URL confusion matrix: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion_matrix.html

[10] B. Efron and R. Tibshirani, "Bootstrap Methods for Standard Errors, Confidence Intervals, and Other Measures of Statistical Accuracy," Statistical Science, 1(1), 1986. doi: 10.1214/ss/1177013815.
URL chính thức: https://doi.org/10.1214/ss/1177013815

[11] N. Reimers and I. Gurevych, "Reporting Score Distributions Makes a Difference," EMNLP, 2017. doi: 10.18653/v1/D17-1035.
URL chính thức: https://aclanthology.org/D17-1035/

[12] X. Bouthillier et al., "Accounting for Variance in Machine Learning Benchmarks," MLSys, 2021.
URL chính thức: https://proceedings.mlsys.org/paper_files/paper/2021/hash/0184b0cd3cfb185989f858a1d9f5c1eb-Abstract.html

[13] G. C. Cawley and N. L. C. Talbot, "On Over-fitting in Model Selection and Subsequent Selection Bias in Performance Evaluation," JMLR, 11, 2010, pp. 2079–2107.
URL chính thức: https://www.jmlr.org/papers/v11/cawley10a.html

[14] PyTorch 2.2, "Reproducibility," official documentation.
URL chính thức: https://docs.pytorch.org/docs/2.2/notes/randomness.html

[15] D. R. Roberts et al., "Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure," Ecography, 40, 2017, pp. 913–929. doi: 10.1111/ecog.02881.
URL chính thức: https://doi.org/10.1111/ecog.02881

[16] S. Kapoor and A. Narayanan, "Leakage and the reproducibility crisis in machine-learning-based science," Patterns, 4(9), 2023, 100804. doi: 10.1016/j.patter.2023.100804.
URL chính thức: https://doi.org/10.1016/j.patter.2023.100804

[17] TorchVision 0.17, "Models and pre-trained weights," official documentation.
URL chính thức: https://docs.pytorch.org/vision/0.17/models.html

[18] P. Chao et al., "HarDNet: A Low Memory Traffic Network," ICCV, 2019.
URL chính thức:
https://openaccess.thecvf.com/content_ICCV_2019/html/Chao_HarDNet_A_Low_Memory_Traffic_Network_ICCV_2019_paper.html

Nguồn nội bộ có thể tái lập

model_benchmark/runs/final_test_v2/final_comparison.json — aggregate qua seed và paired bootstrap.

model_benchmark/runs/final_test_v2/test_open_audit.json — audit mở test.

model_benchmark/runs/final_test_v2/<model>/seed_<seed>/test_metrics.json — metric, per-class, confusion, CI per run.

model_benchmark/runs/final_test_v2/<model>/seed_<seed>/test_predictions.csv — 9.829 dự đoán/run.

model_benchmark/runs/training_v2/<model>/seed_<seed>/run_manifest.json — provenance, validation best, duration, checkpoint SHA.

model_benchmark/config/benchmark_contract_v2.json và campaign_lock_v2.json — protocol/lock.

research/data/splits/rice_cleaned_v4_exact_cross_label_conflicts_excluded_v1.metadata.json — curation/split provenance.

Phụ lục A. Kết quả từng seed

Mô hình	Seed	Accuracy	Macro-P	Macro-R	Macro-F1	CI95 bootstrap F1
MobileNetV2	42	98.861%	96.459%	97.310%	96.829%	[96.017%; 97.507%]
MobileNetV2	123	98.209%	94.384%	96.175%	95.128%	[94.183%; 95.946%]
MobileNetV2	2026	98.789%	96.052%	97.238%	96.596%	[95.739%; 97.285%]
MobileNetV3-Large	42	99.196%	97.499%	97.629%	97.545%	[96.886%; 98.154%]
MobileNetV3-Large	123	99.115%	97.374%	97.391%	97.363%	[96.538%; 97.999%]
MobileNetV3-Large	2026	99.084%	96.820%	97.348%	97.062%	[96.250%; 97.737%]
ResNet-18	42	99.115%	97.349%	97.876%	97.592%	[96.853%; 98.212%]
ResNet-18	123	99.135%	97.053%	97.421%	97.206%	[96.413%; 97.858%]
ResNet-18	2026	98.443%	95.481%	96.317%	95.835%	[94.947%; 96.633%]
EfficientNet-B0	42	99.267%	97.548%	98.066%	97.784%	[97.122%; 98.379%]
EfficientNet-B0	123	99.318%	97.449%	97.972%	97.693%	[96.947%; 98.324%]
EfficientNet-B0	2026	99.308%	97.605%	98.062%	97.817%	[97.080%; 98.409%]
ShuffleNet V2 1.0×	42	97.426%	91.459%	94.663%	92.696%	[91.508%; 93.691%]

Mô hình	Seed	Accuracy	Macro-P	Macro-R	Macro-F1	CI95 bootstrap F1
ShuffleNet V2 1.0×	123	96.490%	90.090%	92.768%	90.899%	[89.755%; 91.958%]
ShuffleNet V2 1.0×	2026	95.686%	88.406%	91.759%	89.317%	[88.212%; 90.431%]
DenseNet-121	42	98.810%	95.927%	96.900%	96.357%	[95.488%; 97.079%]
DenseNet-121	123	98.820%	96.135%	97.187%	96.622%	[95.763%; 97.319%]
DenseNet-121	2026	99.033%	96.659%	97.366%	96.993%	[96.184%; 97.711%]

Phụ lục Bảng A1. CI bootstrap là bất định ảnh test trong từng checkpoint, không phải CI của mean ba seed.

Phụ lục B. Mean F1 theo 19 lớp

Canonical class	n	Eff-B0	MV3-L	RN18	DN121	MV2	Shuffle
bacterial_leaf_blight	270	97.73	97.56	97.83	96.99	95.65	92.78
bacterial_leaf_streak	57	96.62	96.55	96.34	92.84	93.84	71.22
bacterial_panicle_blight	50	97.99	95.67	94.06	93.16	95.80	89.61
beetle	93	100.00	100.00	99.64	99.82	100.00	98.93
blast	251	94.95	94.05	92.64	92.51	91.53	79.90
brown_planthopper	2786	99.95	99.89	99.75	99.83	99.82	99.05
brown_spot	330	98.17	97.33	96.79	96.00	96.32	91.40
dead_heart	215	99.46	98.83	98.76	98.91	98.91	95.82
downy_mildew	93	92.94	91.91	90.16	89.18	86.52	74.56
golden_apple_snail	122	99.86	100.00	99.59	100.00	100.00	99.19
leaf_roller	1764	99.94	99.97	99.80	99.91	99.76	99.08
leaf_smut	21	93.76	93.65	92.68	94.50	93.76	90.43
normal	263	97.41	95.68	96.70	96.51	95.64	90.34
sheath_blight	98	99.49	99.49	99.83	99.66	100.00	99.15
southern_black_streaked_dwarf	12	100.00	100.00	100.00	100.00	100.00	100.00
stem_borer	2973	99.96	99.93	99.75	99.81	99.74	99.18
tungro	163	94.14	93.07	92.79	93.28	89.40	75.88
weeds	239	95.15	95.56	93.57	93.56	90.81	81.94
whitebacked_planthopper	29	100.00	100.00	100.00	100.00	100.00	100.00

Phụ lục Bảng B1. Mean F1 (%) qua ba seed; không có paired CI theo lớp.

Phụ lục C. Class support và trọng số loss

#	Canonical class	Tên diễn giải tiếng Việt	Test n	Effective-number weight
0	bacterial_leaf_blight	bạc lá vi khuẩn	270	0.376080
1	bacterial_leaf_streak	sọc lá vi khuẩn	57	1.153245

#	Canonical class	Tên diễn giải tiếng Việt	Test n	Effective-number weight
2	bacterial_panicle_blight	cháy bông vi khuẩn	50	1.281286
3	beetle	bọ cánh cứng	93	0.769298
4	blast	đạo ôn	251	0.390291
5	brown_planthopper	rầy nâu	2786	0.269471
6	brown_spot	đốm nâu	330	0.342932
7	dead_heart	nõn héo	215	0.425185
8	downy_mildew	sương mai	93	0.767873
9	golden_apple_snail	ốc bươu vàng	122	0.623243
10	leaf_roller	sâu cuốn lá	1764	0.269542
11	leaf_smut	than lá	21	2.942473
12	normal	bình thường	263	0.380669
13	sheath_blight	khô vằn	98	0.738151
14	southern_black_streaked_dwarf	lùn sọc đen phương Nam	12	4.945561
15	stem_borer	sâu đục thân	2973	0.269471
16	tungro	tungro	163	0.506482
17	weeds	cỏ dại	239	0.401034
18	whitebacked_planthopper	rầy lưng trắng	29	2.147714

Phụ lục Bảng C1. Trọng số tính từ train split bằng effective number, β=0,999, chuẩn hóa mean và clip [0,25; 5].

Phụ lục D. Checklist tái lập và viết bài

☐ Giữ nguyên split/contract/campaign lock SHA trong bản thảo và code release.

☐ Báo đầy đủ 18 run; không chỉ chọn seed tốt nhất.

☐ Ghi mean ± sample SD qua seed; không gọi SD là CI95.

☐ Ghi test-image bootstrap CI riêng; không trộn với seed variability.

☐ Ghi rõ paired bootstrap chỉ V3-Large vs năm model, theo từng seed, chưa multiplicity correction.

☐ Luôn báo class support cạnh per-class F1.

☐ Ghi split image-level và chưa có external/grouped validation.

☐ Không đưa Weighted-F1/AUC/ECE/FLOPs/latency nếu chưa chạy phân tích bổ sung.

☐ Tách nghiên cứu backbone khỏi nghiên cứu Grad-CAM/Hybrid CAM.

☐ Không dùng final test để điều chỉnh campaign V2 sau khi đã mở.